

Inventaire des Datasets pour les Langues Africaines (Mise à jour exhaustive)

Recherche automatisée

August 22, 2026

Introduction

Cette liste est une mise à jour substantielle de l'inventaire précédent. Elle intègre de nombreuses nouvelles ressources découvertes via des recherches approfondies sur Hugging Face, Kaggle, Zenodo, GitHub et autres plateformes. L'objectif est de fournir un panorama aussi complet que possible des datasets publics pour le traitement automatique des langues africaines.

1 Datasets Textuels (Corpus, Traduction, NLP) - Nouveaux ajouts

2 Datasets Audio (ASR et TTS) - Nouveaux ajouts

3 Benchmarks et Ressources Complémentaires - Nouveaux ajouts

Remarques sur les Sources

Les plateformes principales pour trouver ces données sont:

- **Hugging Face**: Plateforme majeure hébergeant la majorité des datasets textuels et audio (AfriCorpus, Code-170k, MasakhaNER, WAXAL, MAFAND, etc.).
- **Kaggle**: Plateforme pour les compétitions, avec des datasets comme le South African Language ID, Tiv Q&A, et Luganda-Swahili TTS.
- **Mozilla Common Voice / Data Collective**: Source importante pour les initiatives communautaires (IADH) et les données vocales.
- **GitHub**: Dépôts pour les benchmarks (IrokoBench, Injongo, AfroBench) et les ressources spécifiques (Masakhane, DSFSI).
- **Zenodo**: Plateforme pour les corpus parallèles et autres ressources textuelles (Dholuo corpus, DVox).
- **ACL Anthology / arXiv**: Sources pour les papiers de recherche introduisant de nouveaux datasets (AFRIDOC-MT, AfriMMT-EA, etc.).

Table 1: Nouveaux datasets textuels identifiés

Nom du Dataset	Description	Langues	Lien Source
African Fine Translations	Corpus de phrases pour la traduction automatique.	Afr.Latn, etc.	https://huggingface.co/datasets/AfriNLP/AfricanFineTranslations-sentence
AfriNLLB-train-distilled	Dataset curaté pour l’entraînement des modèles AfriNLLB.	Multipl	https://huggingface.co/datasets/AfriNLP/AfriNLLB-train-distilled
African Languages Lab Multi-Open	Texte parallèle anglais-langue cible pour 31 langues africaines.	31 langues africaines	https://huggingface.co/datasets/African-Languages-Lab/multi-open
MAFAND-MT	Plus grand benchmark de traduction automatique pour les langues africaines dans le domaine de l’actualité, couvrant 21 langues.	Amharique, Bambara, Ghomala, Ewe, Fon, Haoussa, Igbo, Kinyarwanda, etc.	https://huggingface.co/datasets/nehahumbe/mafand
XNLI Extension for African Languages	Extension du corpus XNLI pour l’inférence en langues naturelles (NLI).	Haoussa, Igbo, Kikuyu, Yoruba	https://huggingface.co/datasets/.../xnli-extension-african
MasakhaNER-X	Agrégation des datasets MasakhaNER 1.0 et 2.0 pour 20 langues africaines.	20 langues africaines	https://huggingface.co/datasets/masakhane/masakhaner-x
Kencorpus	Corpus kenyan de textes et de discours pour le NLP.	Swahili, Dholuo, Luhya	https://huggingface.co/datasets/.../kencorpus
AFRIDOC-MT	Corpus de traduction multilingue au niveau du document.	Anglais, Amharique, Haoussa, Swahili, Yoruba, Zoulou	https://aclanthology.org/...
AfriMMT-EA	Dataset de traduction automatique multilingue à grande échelle couvrant 53 langues d’Afrique de l’Est.	53 langues d’Afrique de l’Est	https://experts.umn.edu/...
Adja-French Parallel Corpus	Premier corpus parallèle pour la traduction automatique de l’Adja.	Adja, Français	https://aclanthology.org/...
Dholuo–English Parallel Corpus	Corpus parallèle Dholuo-Anglais de 20 000 paires de phrases.	Dholuo, Anglais	https://doaj.org/...
AfriQuAD	Dataset pour les tâches de Question-Réponse (QA) dans différentes langues africaines.	Multipl	https://huggingface.co/datasets/amidblue/AfriQuAD
KenLumachiQuAD	Dataset de QA pour la langue Luhya	Luhya Lumarachi	https://

Table 2: Nouveaux datasets audio identifiés

Nom du Dataset	Description	Langues	Lien Source
WAXAL (Google Research)	Large corpus ASR (1 250h) et TTS (20h+) pour 21 langues d’Afrique subsaharienne.	Acholi, Haoussa, Luganda, Yoruba, etc. (27 langues au total)	https://huggingface.co/datasets/google/WaxalNLP
Swivuriso (African Next Voices - ZA)	Dataset vocal multilingue de 3000 heures pour l’ASR en 7 langues sud-africaines.	7 langues sud-africaines	https://arxiv.org/abs/...
AfriVox-Transcribe	Benchmark ASR combinant des ensembles de test de 20 langues africaines.	20 langues africaines	https://huggingface.co/datasets/intronhealth/afri vox-transcribe
BibleTTS	Corpus vocal haute fidélité pour la TTS en 10 langues d’Afrique subsaharienne.	10 langues d’Afrique subsaharienne	https://huggingface.co/papers/2207.03546
Luhya ASR Data	Corpus vocal de 70 heures en Luhya.	Luhya	Mozilla Data Collective
DVox (Dvoice)	Dataset ASR pour les langues et dialectes africains.	Wolof, Mandingue, Serere, Pulaar, etc.	https://zenodo.org/record/6342622
Keyword Spotting with African Languages	Extension du dataset Speech Commands avec 6 langues sénégalaises.	Wolof, Pulaar, Serer, Mandinka, Diola, Soninke	https://zenodo.org/...
Synthetic Text Corpus for African Language ASR	13 488 phrases synthétiques pour l’ASR dans 10 langues africaines.	Bambara, Chichewa, Haoussa, Kanuri, Luo, Nande, Somali, Twi, Wolof, Yoruba	https://mozilladatacollective.com/...
Adamawa Fulfulde–French Parallel Corpus	1 977 lignes de narratifs Fulfulde avec traductions françaises.	Fulfulde, Français	Mozilla Data Collective

Table 3: Nouveaux benchmarks et ressources complémentaires identifiés

Nom du Dataset	Description	Langues	Lien Source
IrokoBench	Benchmark traduit manuellement pour 16 langues africaines (NLI, MMLU, MGSM).	16 langues africaines	https://huggingface.co/collections/masakhane/irokobench
Masakhane-NLU	Projet de création de datasets de benchmark pour AfricaNLI, AfricaMGSM, AfricaMMLU.	Multiples	https://github.com/masakhane-io/masakhane-nlu
DSFSI Public Datasets Registry	Catalogue complet de 50+ datasets pour les langues sud-africaines et africaines.	Multiples	https://github.com/dsfsi/dsfsi-datasets
African Speech-Text Datasets	Collection de datasets speech-text pour les langues africaines.	Multiples	https://huggingface.co/collections/michsethowusu/afri-code-datasets
African-African Parallel Sentences	Paires de phrases parallèles entre langues africaines.	Multiples	https://huggingface.co/collections/michsethowusu/afri-code-datasets
Datasets IADH (Mozilla Data Collective)	38 datasets originaux couvrant plus de 20 langues africaines.	Adamawa Fulfulde, etc.	Mozilla Data Collective